

作业 7

姓名：杜一郎

学号：2023011618

2026 年 6 月 17 日

7.1. UCB1

解. (1) UCB1 的选择公式可以写为

$$A_{t+1} = \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right].$$

其中 $Q_t(a)$ 是动作 a 在已有 t 次尝试后的样本平均回报估计， $N_t(a)$ 是动作 a 已被选择的次数， c 是探索系数。若某个动作尚未被选择，一般令其 UCB 值为 $+\infty$ ，以保证该动作至少被探索一次。

上式中， $Q_t(a)$ 反映当前对动作收益的估计，数值越大表示越倾向于利用已经表现较好的动作； $c\sqrt{\ln t/N_t(a)}$ 是探索项，动作被选择次数 $N_t(a)$ 越少，该项越大，从而鼓励算法尝试不确定性较高的动作。随着总尝试次数 t 增大， $\ln t$ 使探索需求缓慢增加；随着某个动作被反复选择， $N_t(a)$ 增大，该动作的探索加成会下降。因此 UCB1 在利用高平均回报动作和探索低访问次数动作之间进行动态平衡。

(2) 已知

$$k = 3, \quad t = 10, \quad c = 1.5,$$

以及

$$N_{10}(a_1) = 5, \quad Q_{10}(a_1) = 1.2,$$

$$N_{10}(a_2) = 3, \quad Q_{10}(a_2) = 1.8,$$

$$N_{10}(a_3) = 2, \quad Q_{10}(a_3) = 1.0.$$

由于第 11 步决策前已经完成了前 10 次尝试，因此代入 $t = 10$ 得

$$\text{UCB}(a_1) = 1.2 + 1.5 \sqrt{\frac{\ln 10}{5}} \approx 2.2179,$$

$$\text{UCB}(a_2) = 1.8 + 1.5 \sqrt{\frac{\ln 10}{3}} \approx 3.1141,$$

$$\text{UCB}(a_3) = 1.0 + 1.5 \sqrt{\frac{\ln 10}{2}} \approx 2.6095.$$

动作	UCB
a_1	2.2179
a_2	3.1141
a_3	2.6095

因此第 11 步应选择 a_2 。

(3) 无偏样本平均的增量更新公式为

$$Q_{n+1}(a) = Q_n(a) + \frac{1}{N_{n+1}(a)}(R_{n+1} - Q_n(a)),$$

其中 $N_{n+1}(a) = N_n(a) + 1$ 。第 11 步选择的是 a_2 ，并且得到回报 $R_{11} = 2.4$ ，所以

$$\begin{aligned} N_{11}(a_2) &= N_{10}(a_2) + 1 = 4, \\ Q_{11}(a_2) &= Q_{10}(a_2) + \frac{1}{N_{11}(a_2)}(R_{11} - Q_{10}(a_2)) \\ &= 1.8 + \frac{1}{4}(2.4 - 1.8) = 1.95. \end{aligned}$$

其余动作在第 11 步未被选择，因此统计参数保持不变：

$$N_{11}(a_1) = 5, \quad Q_{11}(a_1) = 1.2,$$

$$N_{11}(a_3) = 2, \quad Q_{11}(a_3) = 1.0.$$

在第 12 步决策前，所有动作的最新统计参数为：

动作	N_{11}	Q_{11}
a_1	5	1.20
a_2	4	1.95
a_3	2	1.00