

作业 8

姓名：杜一郎

学号：2023011618

2026 年 6 月 17 日

8.1. 两状态 MDP

状态集合 $\mathcal{S} = \{s_0, s_1\}$ ，动作集合 $\mathcal{A} = \{a_0, a_1\}$ ，折扣因子 $\gamma = 0.9$ 。

解. (1)

策略为

$$\pi(s_0) = a_1, \quad \pi(s_1) = a_0,$$

题目中还给出

$$U^\pi(s_0) = 5.$$

状态 s_1 下执行 a_0 ：以 0.8 概率转移到 s_0 ，奖励为 2；以 0.2 概率转移到 s_1 ，奖励为 0。Bellman 方程为

$$\begin{aligned} U^\pi(s_1) &= 0.8(2 + \gamma U^\pi(s_0)) + 0.2(0 + \gamma U^\pi(s_1)) \\ &= 0.8(2 + 0.9 \times 5) + 0.2 \times 0.9 U^\pi(s_1). \end{aligned}$$

整理得

$$(1 - 0.18)U^\pi(s_1) = 5.2,$$

解得

$$U^\pi(s_1) = \frac{5.2}{0.82} \approx 6.3415.$$

(2)

看 s_0 改选 a_0 时的动作价值。执行 a_0 时，以 0.7 概率转移到 s_0 ，奖励为 1；以 0.3 概率转移到 s_1 ，奖励为 3。于是

$$\begin{aligned} Q^\pi(s_0, a_0) &= 0.7(1 + \gamma U^\pi(s_0)) + 0.3(3 + \gamma U^\pi(s_1)) \\ &= 0.7(1 + 0.9 \times 5) + 0.3(3 + 0.9 \times 6.3415) \\ &\approx 6.4622. \end{aligned}$$

这里

$$Q^\pi(s_0, a_0) \approx 6.4622 > U^\pi(s_0) = 5,$$

s_0 处把策略从 a_1 改为 a_0 会提高价值，即

$$\pi_{\text{new}}(s_0) = a_0.$$

8.2. 3×3 Gridworld

状态编号如下：

$$\begin{array}{ccc} s_1 & s_2 & s_3 \\ s_4 & s_5 & s_6 \\ s_7 & s_8 & s_9 \end{array}$$

其中 s_9 为终止状态， $V(s_9) = 0$ 。动作集合为

$$\mathcal{A} = \{\text{Up, Down, Left, Right}\}.$$

每走一步奖励 $R = -1$ ，折扣因子 $\gamma = 1$ 。若动作撞墙，则停留在原状态。初始价值为

$$V_0(s) = 0, \quad s \in \{1, 2, \dots, 9\},$$

初始策略为均匀随机策略

$$\pi_0(a|s) = 0.25.$$

解. (1)

第一次迭代用

$$V_{k+1}(s) = \sum_a \pi_0(a|s) [-1 + V_k(s')].$$

由 $V_0(s) = 0$ ，所有非终止状态都有

$$V_1(s) = -1, \quad s = 1, 2, \dots, 8.$$

终止状态仍为

$$V_1(s_9) = 0.$$

(2)

第二次迭代时，非终止后继状态的 V_1 为 -1 ，终止状态 s_9 的价值为 0 。

对 s_5 ，四个方向分别到达 s_2, s_8, s_4, s_6 ，都不是终止状态，故

$$V_2(s_5) = \frac{1}{4}[(-1 - 1) + (-1 - 1) + (-1 - 1) + (-1 - 1)] = -2.$$

对 s_6 ，向上到 s_3 ，向下到 s_9 ，向左到 s_5 ，向右撞墙仍在 s_6 。代入得

$$V_2(s_6) = \frac{1}{4}[(-1 - 1) + (-1 + 0) + (-1 - 1) + (-1 - 1)] = -\frac{7}{4} = -1.75.$$

对 s_8 ，向上到 s_5 ，向下撞墙仍在 s_8 ，向左到 s_7 ，向右到 s_9 。代入得

$$V_2(s_8) = \frac{1}{4}[(-1-1) + (-1-1) + (-1-1) + (-1+0)] = -\frac{7}{4} = -1.75.$$

(3)

用 V_2 做策略改进：

$$\pi_1(s) = \arg \max_a [-1 + V_2(s')].$$

用到的几个值是

$$V_2(s_2) = V_2(s_3) = V_2(s_4) = V_2(s_5) = -2,$$

$$V_2(s_6) = V_2(s_8) = -1.75,$$

$$V_2(s_9) = 0.$$

在 s_5 处：

动作	$-1 + V_2(s')$
Up	-3
Down	-2.75
Left	-3
Right	-2.75

最优动作有两个：

$$\pi_1(s_5) \in \{\text{Down}, \text{Right}\}.$$

在 s_6 处：

动作	$-1 + V_2(s')$
Up	-3
Down	-1
Left	-3
Right	-2.75

最优动作为

$$\pi_1(s_6) = \text{Down}.$$

8.3. Monte Carlo 价值估计

状态集合 $\mathcal{S} = \{A, B\}$, 终止状态 T , 折扣因子 $\gamma = 1$ 。已采样得到三条轨迹:

$$\begin{aligned} 1: & A \xrightarrow{R=-1} B \xrightarrow{R=-1} A \xrightarrow{R=-2} B \xrightarrow{R=+6} T, \\ 2: & B \xrightarrow{R=-2} B \xrightarrow{R=-1} A \xrightarrow{R=+5} T, \\ 3: & A \xrightarrow{R=-1} A \xrightarrow{R=-3} B \xrightarrow{R=+4} T. \end{aligned}$$

解. (1) First-visit Monte Carlo

先算每条轨迹中每个状态第一次出现时的回报。

第 1 条轨迹:

$$G(A) = -1 - 1 - 2 + 6 = 2, \quad G(B) = -1 - 2 + 6 = 3.$$

第 2 条轨迹:

$$G(B) = -2 - 1 + 5 = 2, \quad G(A) = 5.$$

第 3 条轨迹:

$$G(A) = -1 - 3 + 4 = 0, \quad G(B) = 4.$$

first-visit 估计为

$$\begin{aligned} V(A) &= \frac{2 + 5 + 0}{3} = \frac{7}{3} \approx 2.3333, \\ V(B) &= \frac{3 + 2 + 4}{3} = 3. \end{aligned}$$

(2) Every-visit Monte Carlo

every-visit 要把同一条轨迹里同一状态的多次出现都计入平均。

状态 A 的所有回报为

$$2, 4, 5, 0, 1.$$

于是

$$V(A) = \frac{2 + 4 + 5 + 0 + 1}{5} = \frac{12}{5} = 2.4.$$

状态 B 的所有回报为

$$3, 6, 2, 4, 4.$$

于是

$$V(B) = \frac{3 + 6 + 2 + 4 + 4}{5} = \frac{19}{5} = 3.8.$$