

人工智能原理课程项目 2：CNN 图像分类

姓名：杜一郎 学号：2023011618

1 任务与数据

这次任务是在 STL10 数据集上做 10 类图像分类，并比较数据增强、激活函数、池化、Dropout 和 Batch Normalization 等设置。数据目录中训练集 7000 张、测试集 1000 张，每类训练样本 700 张、测试样本 100 张，图片为 96×96 RGB 图像。

代码放在 `question_sets/ai_intro_hw/08_project2_scripts/stl10_cnn_experiment.py`，结果保存在 `question_sets/ai_intro_hw/08_project2_results/cnn_stl10`。本机 CPU 训练比较慢，所以输入统一缩放到 48×48 ，每组只训练 3 个 epoch。这样能跑完对照实验，但精度不能和长时间训练的模型相比。

2 方法

程序使用自定义 `ImageFolderDataset` 读取 PNG 图片，不依赖 `torchvision`。训练增强包括随机裁剪和随机水平翻转，测试阶段使用中心裁剪。归一化均值为

$$(0.4467, 0.4398, 0.4066),$$

标准差为

$$(0.2603, 0.2566, 0.2713).$$

网络由四个卷积块组成，每个卷积块包含 3×3 卷积、可选 Batch Normalization、激活函数和池化层。最后使用全局平均池化、Dropout 和全连接层输出 10 类 logits：

$$\text{Conv}(3, 32) \rightarrow \text{Conv}(32, 64) \rightarrow \text{Conv}(64, 128) \rightarrow \text{Conv}(128, 256) \rightarrow \text{GAP} \rightarrow \text{Linear}(256, 10).$$

损失函数为交叉熵，优化器为 Adam，学习率 10^{-3} ，权重衰减 10^{-4} ，学习率调度使用 `CosineAnnealingLR`。

3 对照实验

四组实验如下。基线只用 ReLU 和 MaxPool；其余三组分别看增强加正则化、Tanh+AvgPool 和 Sigmoid 激活。这里不是严格的单变量消融，尤其是最好的一组同时加入了增强、BN 和 Dropout，所以结论只对应这几组组合设置。

表 1: 实验设置

实验名称	激活函数	池化	BatchNorm	Dropout	数据增强
baseline_relu_max	ReLU	Max	否	0.00	否
aug_bn_dropout_relu_max	ReLU	Max	是	0.35	是
tanh_avg_bn_dropout	Tanh	Avg	是	0.35	是
sigmoid_max_bn_dropout	Sigmoid	Max	是	0.35	是

4 结果

表 2: 测试集指标

实验名称	Loss	Accuracy	Precision	Recall	F1-score
baseline_relu_max	1.5197	0.415	0.438	0.415	0.417
aug_bn_dropout_relu_max	1.2848	0.519	0.562	0.519	0.522
tanh_avg_bn_dropout	1.7564	0.356	0.363	0.356	0.326
sigmoid_max_bn_dropout	1.6959	0.344	0.395	0.344	0.319

表现最好的是 `aug_bn_dropout_relu_max`, Accuracy 为 0.519, 宏平均 F1 为 0.522。它比基线高一些, 但这部分提升不能单独归因到某一个技巧, 因为增强、BN 和 Dropout 是一起加进去的。Tanh+AvgPool 和 Sigmoid+MaxPool 的结果低于 ReLU+MaxPool; 在这个浅层 CNN 上, Sigmoid/Tanh 训练更慢, AvgPool 也会削弱一部分局部强响应。

表 3: 最佳模型逐类指标

类别	Precision	Recall	F1-score
airplane	0.756	0.650	0.699
bird	0.394	0.540	0.456
car	0.785	0.620	0.693
cat	0.419	0.360	0.387
deer	0.518	0.440	0.476
dog	0.380	0.350	0.365
horse	0.767	0.460	0.575
monkey	0.358	0.590	0.445
ship	0.503	0.800	0.618
truck	0.745	0.380	0.503

混淆矩阵如下, 行是真实类别, 列是预测类别, 类别顺序为 airplane、bird、car、cat、deer、dog、horse、monkey、ship、truck。

表 4: 最佳模型混淆矩阵

	air	bird	car	cat	deer	dog	horse	monkey	ship	truck
airplane	65	6	2	0	0	0	1	1	21	4
bird	5	54	0	5	4	5	0	27	0	0
car	2	6	62	3	0	2	2	1	15	7
cat	0	19	0	36	5	11	0	28	1	0
deer	0	10	2	11	44	7	5	21	0	0
dog	0	16	0	11	15	35	5	17	1	0
horse	0	7	0	4	11	20	46	9	3	0
monkey	0	11	0	13	5	12	0	59	0	0
ship	8	5	2	1	1	0	0	1	80	2
truck	6	3	11	2	0	0	1	1	38	38

airplane、car 和 ship 的 F1 较高。动物类之间混淆比较多，尤其 cat、dog、monkey 经常互相误判。truck 的 precision 较高但 recall 只有 0.380，说明模型预测 truck 时比较谨慎，但漏掉了不少真实 truck，其中 38 张被判成 ship。

5 Grad-CAM

对最佳模型最后一个卷积层做 Grad-CAM，选取三张样本如下。



图 1: Grad-CAM 示例。左：airplane 被预测为 ship；中：cat 正确分类；右：ship 正确分类。

从图上看，正确分类的 cat 和 ship 样本中，响应主要落在目标主体附近。误分类的 airplane 样本里，热区覆盖了大面积蓝色背景和细长主体，这也对应混淆矩阵中 airplane 被判成 ship 的情况。

6 局限

这次没有单独划分验证集，训练脚本每轮直接在测试集上评估，并按测试集 F1 保存最佳模型。所以表中数值适合作为课程项目内的对照结果，不应当写成严格的泛化性能。另一个限制是训练只有 3 个 epoch，输入也从 96×96 降到 48×48 ，动物类细节损失比较大。

7 AI 工具使用说明

写报告时使用了 AI 工具帮助整理结构、检查表述和排版问题。代码实现、实验设置、运行结果和指标解释都按本地脚本与输出文件核对过，最后的内容由本人修改确认。

8 复现方式

```
python .\question_sets\ai_intro_hw\08_project2_scripts\stl10_cnn_experiment.py ^  
--preset main --epochs 3 --batch-size 64 --image-size 48 ^  
--data-dir .\question_sets\ai_intro_hw\08_项目2_CNN_STL10\STL10 ^  
--output-dir .\question_sets\ai_intro_hw\08_project2_results\cnn_stl10 ^  
--gradcam
```