

人工智能原理项目 3: Pac-Man 强化学习

姓名: 杜一郎 学号: 2023011618

1 问题建模

题目给定一个 5×5 Pac-Man 网格环境。Pac-Man 初始位置为 $(0, 0)$, 终点为 $(4, 4)$ 。两颗豆子位于 $(0, 2)$ 、 $(2, 3)$, 三个静止幽灵位于 $(1, 2)$ 、 $(2, 1)$ 、 $(3, 3)$ 。动作集合为

$$A = \{\text{上, 下, 左, 右}\}.$$

如果动作越界, Pac-Man 停在原地并受到撞墙惩罚。

2 状态与转移概率

原模板只返回当前位置编号, 但吃豆子会改变后续奖励。如果只用位置作为状态, 同一个格子在“豆子已吃”和“豆子未吃”时会被合并。所以代码把状态扩展为

$$s = (\text{row}, \text{col}, \text{bean_mask}),$$

其中 bean_mask 用两位二进制记录两颗豆子是否已经被吃掉。最多状态数为

$$25 \times 4 = 100.$$

环境是确定性的。对任意状态 s 和动作 a , 代码中的 `transition(state, action)` 会给出唯一后继状态 s' 。因此转移概率为

$$P(s'|s, a) = 1,$$

其他后继状态的概率为

$$P(\tilde{s}|s, a) = 0, \quad \tilde{s} \neq s'.$$

终止状态包括撞到幽灵, 以及到达终点。

3 奖励函数

表 1: 奖励设置

情况	奖励
普通移动	-1
撞墙	-10
吃到新豆子	+10
撞幽灵	-100
吃完豆子后到达终点	+100
未吃完豆子就到达终点	额外 -20

普通移动给负奖励，这样策略会更偏向短路径；幽灵惩罚较大，避免策略为了吃豆子走进危险格。

4 值迭代

值迭代使用 Bellman 最优方程：

$$V(s) = \max_a [R(s, a, s') + \gamma V(s')].$$

因为这个地图可以直接枚举转移，所以对每个非终止状态计算四个动作的动作价值，取最大值更新 $V(s)$ ，并记录对应动作作为策略。参数取

$$\gamma = 0.9, \quad \theta = 10^{-8}.$$

5 Monte Carlo 控制

无模型方法使用 first-visit Monte Carlo control。每个 episode 从起点开始，按 epsilon-greedy 策略选择动作。回合结束后，从后往前计算折扣回报

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots,$$

并只对第一次出现的 (s, a) 更新平均回报。训练结束后，对每个状态取 $Q(s, a)$ 最大的动作作为贪心策略。参数为

$$\text{episodes} = 3000, \quad \epsilon_0 = 0.2, \quad \epsilon_{\min} = 0.02, \quad \gamma = 0.9.$$

6 实验结果

运行命令为

```
cd question_sets\ai_intro_hw\11_项目3_RL_PacMan\codes
python .\Pac-Man.py --episodes 3000 --output-dir ..\project3_outputs
```

值迭代得到的路径如下：

$$(0,0) \rightarrow (0,1) \rightarrow (0,2) \rightarrow (0,3) \rightarrow (1,3) \rightarrow (2,3) \rightarrow (2,4) \rightarrow (3,4) \rightarrow (4,4).$$

动作序列为

右 → 右 → 右 → 下 → 下 → 右 → 下 → 下.

逐步奖励为

-1, 9, -1, -1, 9, -1, -1, 99,

总奖励为

112.

Monte Carlo 训练 3000 个 episode 后，最终贪心策略也得到同一条路径和同一总奖励。




图 1: 值迭代收敛曲线与 Monte Carlo 回报曲线。

左图中 Bellman 更新量下降很快，说明值迭代在这个小状态空间里很快就收敛了。右图是 Monte Carlo 的 100-episode 平均回报，前期波动较大，后期稳定到较高回报附近。代码中记录了 episode reward，没有单独记录每一局的路径长度；最终贪心路径长度为 8 步。

7 学习过程视频

目录中保留了 `question_sets/ai_intro_hw/11_ 项目 3_RL_PacMan/Pac-Man.mp4`，作为学习过程或策略演示附件。PDF 报告里不直接嵌入视频，提交时和报告、代码一起打包。

8 AI 工具使用说明

写报告时使用了 AI 工具辅助整理内容、检查题目覆盖情况和修改文字表述。环境建模、奖励设计、值迭代、Monte Carlo 控制和实验结果都来自本地代码与运行输出，提交前由本人复核。

9 小结

值迭代依赖完整环境模型，可以稳定求出最优策略。Monte Carlo control 不需要显式转移模型，但要通过 episode 采样慢慢估计 $Q(s, a)$ 。在这个 5×5 地图上，两种方法最后都找到同一条 8 步路径：避开幽灵、吃完两颗豆子，再到达终点。